拼音输入法编程作业

软件最终效果

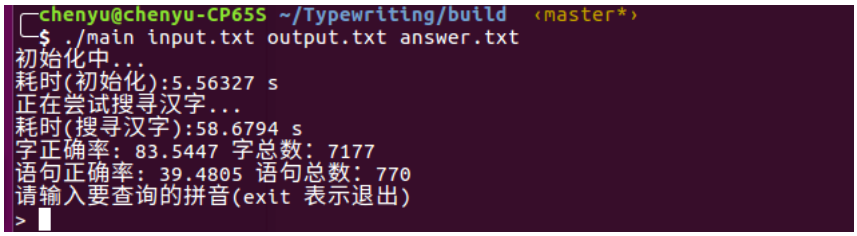

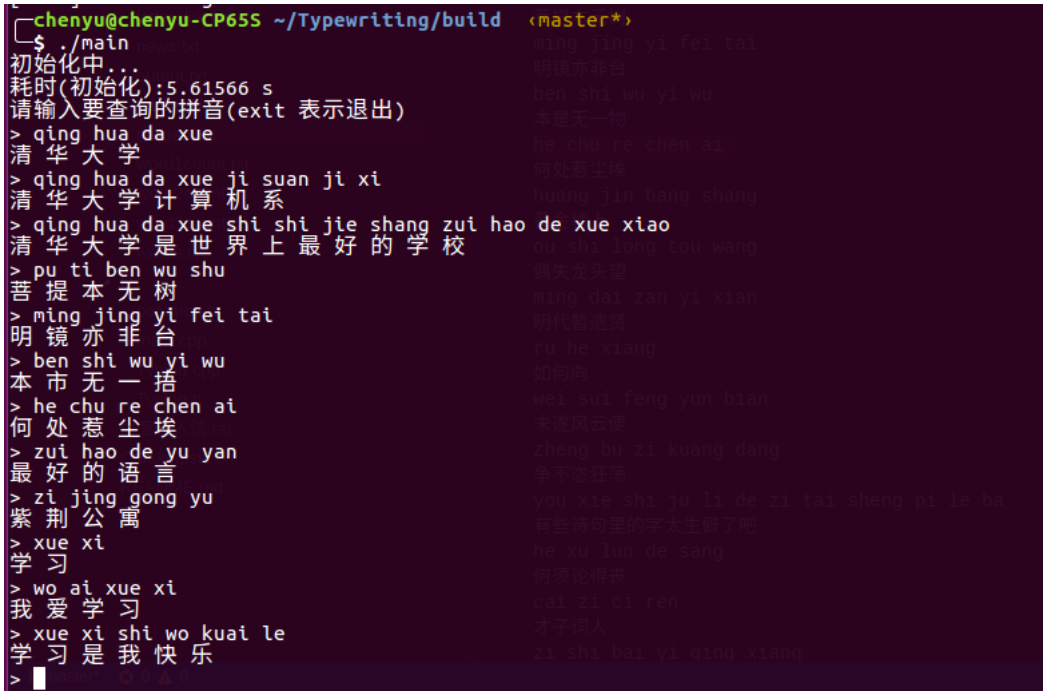

测试集采用网络学堂上采集的测试集，最终字的正确率为83.5%,句子的正确率为39.5%。

算法运行依赖的文件大小约200M，初始化大约5秒钟，查询一条语句大约0.5秒钟;批量处理的时候使用了多线程进行优化。

算法说明

最终算法采用三元概率模型。

首先，整理新闻，分别统计出单个字，两个字和三个字出现的次数;根据贝叶斯公式：

$$P(W_i|W_{i-2}W_{i-1}) = \frac{P(W_{i-2}W_{i-1}W_i)}{P(W_{i-2}W_{i-1})}$$

可以通过频率可以计算出已知前两个字，第三个字出现的概率;

最终，一种方案的得分即使：

$$S = P(W_1) * P(W_2|W_1) * \prod_{3}^{n}(P(W_i|W_{i-2}W_{i-1}))$$

然后，根据这个公式，选择一种最优的方案;注意到上面的公式是可以使用动态规划来加速的，所以最终实现的过程中使用了动态规划。

同时，对于建出的索引，由于有很多出现次数非常小的组合，所以在实际的算法中，对索引进行了过滤，一方面可以减少索引的大小，另一方面可以加速搜索的过程。

其他算法

在实现输入法算法的过程中，也探索了一些其他算法;

首先实验了二元概率算法，其根据是下面两个公式：

$$P(W_i|W_{i-1}) = \frac{P(W_{i-1}W_i)}{P(W_{i-1})}$$

$$S = P(W_1) * \prod_{2}^{n}(P(W_i|W_{i-1}))$$

这两个公式和上面三元的公式非常相似，实际算法实现的过程也很像，最终字的正确率大约76%，语句的正确率大约76%。

其次，尝试使用词语进行优化，但无奈没有找到合适的数学模型，最终最高的语句正确率只有33%。

存在的问题

- 没有考虑多音字，实际上在计算概率P的时候，应该考虑上字的发音
- 没有考虑词性

实验收获

- 了解了拼音输入法的实现原理
- get了一波C++11和多线程的技能